马晨熙

手机：+86 15387087330 · 邮箱：Shannon20051127@gmail.com

教育背景

武汉理工大学（211） 2024.09 - 至今

- **研究方向**：大模型推理框架、MoE 模型推理性能优化、昇腾算力适配

项目经历

基于昇腾（Ascend）的高性能推理框架研发，清华大学 2025.09 - 至今

- **框架开发与适配**：深度参与基于华为昇腾硬件的推理框架研发，负责 Qwen2.5 系列模型在 GE 版本的底层适配与全图下沉执行；围绕模型接入、执行链路打通与算子行为对齐，持续跟进适配过程中的功能正确性与端到端可用性，推动模型在昇腾环境下稳定运行。
- **算子与图优化**：通过图融合（Graph Fusion）技术优化计算图执行路径，针对昇腾架构特性调优核心算子，提升模型部署的稳定性；结合推理图执行特征分析关键瓶颈位置，协同定位图级别与算子级别问题，减少不必要的数据搬运与执行开销。
- **异构加速实践**：利用昇腾算力平台的硬件特性进行针对性加速，实现 Qwen2.5 模型在国产化算力平台上的高性能推理与大规模吞吐优化；参与不同负载场景下的性能测试与结果对比，关注吞吐、延迟与资源利用率之间的平衡，为后续框架演进提供优化依据。

混合专家模型（MoE）推理加速研究，上海交通大学 2025.03 - 2025.09

- **项目背景**：针对大规模混合专家模型（MoE）在推理过程中的专家激活稀疏性问题，开展系统级性能瓶颈分析与计算加速研究；聚焦长文本生成场景下的推理代价拆分，从路由、专家执行与通信协同三个角度分析影响整体效率的关键因素。
- **优化策略**：深入调研 MoE 架构的激活模式，探索基于专家并行的调度策略，研究如何通过 Overlap 计算与通信优化动态路由产生的延迟；围绕专家激活分布与请求批次变化，分析调度策略对系统吞吐和尾延迟的影响，形成针对不同工作负载的优化思路。
- **性能评估**：定量分析不同 Batch Size 下的专家负载不均衡问题，评估异构后端对 MoE 算子的执行效率，旨在提升系统吞吐量并显著优化长文本场景下的首字延迟（TTFT）；对关键实验现象进行归因总结，整理不同并行方式与负载模式下的性能表现，为后续 MoE 推理系统设计提供参考。

自研轻量级高性能深度学习推理框架 2025.1 - 2025.02

- **项目描述**：构建支持 LLaMA 2/3.2、Qwen 等模型的可扩展推理框架，具备 CPU/GPU 双后端，优化模型加载与执行流程以提升速度和资源效率；围绕推理引擎核心链路完成模块设计与实现，兼顾可扩展性与工程可维护性，支持后续模型接入和功能迭代。
- **架构优化**：集成 KV 缓存与连续批处理（Continuous Batching）以支持高效批量推理；使用 Nsight 工具优化 CUDA 算子（RMSNorm、GEMM），吞吐量提升 40%；针对请求调度、显存访问与算子执行热点进行分析，逐步压缩推理链路中的等待时间与冗余开销，改善整体响应效率。
- **量化技术**：应用 INT8 分组量化技术，在保持精度的前提下减少模型大小与延迟，压缩比达 40% 以上；在精度与性能之间进行权衡验证，关注量化后模型在实际推理任务中的可用性与稳定性，形成可复用的部署经验。

专业技能

- **AI 推理框架与性能优化**：掌握 LLaMA/Qwen 等模型的推理框架设计，精通 KV 缓存、分页注意力（PagedAttention）及连续批处理（Continuous Batching）技术。
- **CUDA 算子优化**：擅长使用 Nsight 工具优化 CUDA 算子（GEMM），实现推理吞吐量 40% 提升。
- **模型量化**：熟练应用 INT8 分组量化，兼顾模型压缩与精度保持的工程实践，了解当今主流训推 FP8 量化的技术原理。
- **强化学习基础**：了解 RL 算法原理（策略梯度、PPO、GRPO 等）。
- **性能分析**：熟悉大模型推理中的吞吐、时延、显存占用等核心指标分析方法，能够结合具体执行链路定位性能瓶颈并持续迭代优化。

竞赛获奖

全国大学生数学竞赛 (CMC) 国家二等奖（2024.11）